Школа анализа данных Машинное обучение, часть 1 Теоретическое домашнее задание №2

Кошман Дмитрий

Задача 1 (0.5 балла) Кроссвалидация, LOO, k-fold.

В случае с малым количеством объектов больше подходит LOO-CV, поскольку в этом случае увеличение размера обучающей выборки на 1 объект сильно влияет на качество модели. То есть при увеличении тестовой выборки на 1 качество модели падает сильнее, чем возрастает качество оценки этой модели. - уменьшается разброс между качеством на тесте и трейне, но и качество в среднем падает. Еще следует отметить, что поскольку объектов мало, то и обучить модель столько раз, сколько объектов в выборке можно за адекватное количество времени.

В случае с большим количеством объектов обучать модель столько раз, сколько объектов в выборке займет слишком много времени, поэтому LOO-CV не подходит. Если она очень большая, то даже KFold-CV будет работать слишком долго и лучше просто пользоваться HoldOut. Если нет, KFold-CV скорее всего успеет сойтись на 4/5 объектов и среднее качество не будет сильно отличаться от качества при обучении на всех объектах, но при этом будет хорошая оценка на тестовом фолде, ведь в нем тоже много объектов.

Задача 2 (1.5 балла). Логистическая регрессия, решение оптимизационной задачи.

1. (0.5 балла) Пусть классы имеют метки $\{-1,1\}$. Если выборка линейно разделима, это означает, что существует такое w', что $\forall i: y_i \langle w', x_i \rangle < 0$. Предположим, что существует w, максимизирующее правдоподобие вероятностной модели логистической регрессии, то есть для w достигается максимум

$$L(w, X, y) = \sum_{i=1}^{N} \log \left(1 + e^{-y_i \langle w, x_i \rangle} \right)$$

Но тогда если взять w + w', правдоподобие увеличится - противоречие.

2. (0.3 балла) Предложите, как можно модифицировать модель, чтобы оптимум достигался. Если в вероятностной модели предположить не только существование истинной зависимости между признаками и вероятностью положительного класса, но и априорное распределение на параметрах модели, объясняющееся неточностью измерений, представлений или наличием шума, то модель модифицируется таким образом:

$$p(X, Y, w; \sigma) = p(X, Y \mid w) p(w; \sigma)$$

Принцип максимума совместного правдоподобия данных и модели:

$$L_{\sigma}(w, X, Y) = \ln p(X, Y, w; \sigma) = \sum_{i=1}^{n} \ln p(x_i, y_i \mid w) + \ln p(w; \sigma) \to \max_{w}$$

Если предположить, что w имеет нормальное распределение $w \sim N\left(0, \sigma^2\right)$, где σ - гиперпараметр, то получаем:

$$\ln p(w; \sigma) = \ln \left(\frac{1}{(2\pi\sigma)^{n/2}} \exp \left(-\frac{\|w\|^2}{2\sigma} \right) \right) = -\frac{1}{2\sigma} \|w\|^2 + \text{const}(w)$$

Тогда L_{σ} - непрерывная по w функция, стремящаяся к минус бесконечности при $w \to \infty$, значит она достигает максимума.

3. (0.7 балла) В случае L2- регуляризации логистической регрессии решение всегда единственно. Посмотрим на матрицу вторых производных:

$$\nabla L = -\frac{1}{\sigma}E - X^T D X$$

где D - матрица с положительными числами на диагонали. Тогда:

$$u^T \nabla L u = -\|u\|^2 - \|D^{1/2} X u\|^2 < 0$$

значит максимум единственный.

Задача 3 (0,5 балла). L^2 -регуляризация.

Модифицируем данные следующим образом:

$$Y' = X^T Y$$
$$X' = X^T X + \lambda I$$

Тогда решение задачи наименьших квадратов для этих данных такого:

$$w = (X'^T X')^{-1} X'^T Y'$$

Заметим, что X' симметрична и положительна определена. Значит,

$$w = X'^{-1}Y' = (X^TX + \lambda I)^{-1}X^TY$$

Что есть решение для L^2 -регуляризованной линейной регрессии.

Задача 4 (1.5 балла). L^1 -регуляризация.

1. (0.5 балла)

Поскольку L^1 -регуляризованная линейная регрессия представляет собой сумму квадрата L^2 нормы линейного по w выражения и L^1 нормы w, домноженной на положительную константу, то в целом выражение является выпуклой по w функцией как сумма выпуклых функций. Значит, если минимум выпуклой функции достигается в двух точках, то между этими точками значение функции также равно минимуму, и точек минимума континуум.

2. (0.5 балла)

Рассмотрим два решения \widehat{w} и w. По рассуждениям из предыдущего пункта в точках вида $w+\alpha(\widehat{w}-w)$ функция потерь также равна минимуму для $\alpha\in[0,1]$. Тогда скалярная по α функция

$$|X(w + \alpha(\widehat{w} - w)) - y|_2^2 + \lambda |w + \alpha(\widehat{w} - w)|_1$$

Представляет собой сумму полинома второй степени и непрерывной кусочно-линейной функции, которая может постоянна на отрезке [0,1] только если коэффициент перед квадратом равен нулю, то есть если

$$|X(\widehat{w}-w)|_2^2=0\Rightarrow X(\widehat{w}-w)=0\Rightarrow X\widehat{w}=Xw$$

3. (0.5 балла)

Поскольку для решений \widehat{w} и w значения равны $X\widehat{w}$ и Xw, то

$$min = |Xw - y|_2^2 + \lambda |w|_1 = |X\widehat{w} - y|_2^2 + \lambda |w|_1 = |X\widehat{w} - y|_2^2 + \lambda |\widehat{w}|_1$$
$$|w|_1 = |\widehat{w}|_1$$

1. (0.3 балла)

$$p(y \mid a, b) = \frac{1}{\Gamma(a)b^a} y^{a-1} e^{-\frac{y}{b}} = \frac{exp\{(a-1)\ln y - \frac{y}{b}\}}{\Gamma(a)b^a}$$

Если положить $u_1(x) = \ln x, u_2(x) = -x, \theta_1 = a - 1, \theta_2 = \frac{1}{b}$, то можно переписать функцию плотности:

$$p(y \mid \theta) = \frac{exp\{\theta^T u(y)\}}{\Gamma(\theta_1 + 1)\theta_2^{-\theta_1 - 1}} = \frac{exp\{\theta^T u(y)\}}{h(\theta)}$$

Откуда видно, что гамма-распределение относится к экспоненциальному классу.

2. (0.7 балла)

Положим $\phi=-\frac{1}{a}, \theta=\frac{1}{ab}.$ Тогда $a=-\frac{1}{\phi}, b=-\frac{\phi}{\theta}$ и плотность вероятности представляется в виде

$$\begin{split} p(y\mid a,b) &= \exp\{(a-1)\ln y - \frac{y}{b} - \ln\Gamma(a) - a\ln b\} = \\ &= \exp\{(-\frac{1}{\phi} - 1)\ln y + \frac{\theta y}{\phi} - \ln\Gamma(-\frac{1}{\phi}) + \frac{1}{\phi}\ln - \frac{\phi}{\theta}\} = \\ &= \exp\{\frac{\theta y - \ln\theta}{\phi} + (-\frac{1}{\phi} - 1)\ln y - \ln\Gamma(-\frac{1}{\phi}) + \frac{1}{\phi}\ln - \phi\} = \\ &= \exp\{\frac{\theta y - h(\theta)}{\phi} + g(y,\phi)\} \end{split}$$

где $h(x)=\ln x, h'(x)=\frac{1}{x}$. Значит, мы рассматриваем параметризованное семейство $\Gamma(\frac{1}{\sigma},\frac{\sigma}{< x,w>})$ с фиксированной σ , каноничекая функция связи равна $g(x)=(h'(x))^{-1}=\frac{1}{x}$, и нужно оптимизировать функционал

$$\sum_{i} |g^{-1}(\langle x_i, w \rangle) - y_i|^2 = \sum_{i} \left| \frac{1}{\langle x_i, w \rangle} - y_i \right|^2$$

Задача 7 (0.5 балла) Нейронные сети.

1.
$$L(2,2) \to A \to L(2,1)$$

2.
$$L(2,2) \to A \to L(2,2) \to A \to L(2,1)$$

- 3. $L(2,3) \to L(3,1)$
- 4. $L(2,3) \to A \to L(3,1)$
- 5. $L(2,3) \to L(3,3) \to L(3,1)$

Простым линейным преобразованием нельзя сделать так, чтобы две вложенные окружности оказались на разных полуплоскостях, поскольку линейное преобразование сохраняет порядок на прямой. Значит, варианты 3 и 5 не подходят.

В первом варианте похожая проблема. После любого первого преобразования Wx+b всегда найдутся такие точки x,y из внешней окружности и z из внутренней, что $w_1x+b_1 < w_1z+b_1 < w_1y+b_1$. Поскольку сигмоида монотонна, то этот порядок на первых координатах сохранится и последний линейный слой не сможет разделить эти три точки. Во втором варианте то же самое, поскольку второй линейный слой будет работать с искаженными, но все еще вложенными окружностями, для которых приведенное рассуждение остается верным.

Остается только четвертый вариант. Он сможет разделить эти две окружности, в первом слое проведя три прямые, продолжающие стороны вписанного равностороннего треугольника во внешнюю окружность, а в последнем слое взять сумму координат. Изменяя масштаб коэффициентов в первом слое и границу деления при формировании ответов, можно добиться полного разделения двух классов. Если же окружности лежали плотнее, то для их разделения понадобилось бы больше нейронов в слое активации.

Задача 8 (0.5 балла) Нейронные сети, калибровка.

Ответы нейронной сети на задачу классификации часто не пропорциональны истинным вероятностям классов, поскольку сети обучаются, основываясь на точность предсказаний, а не калибровку. Также глубина сети напрямую связана со сложностью модели, а сложные модели легко переобучаются. Вообще нелинейные преобразования плохо интерпретируются, и без явно поставленной задачи хорошей калибровки нет причин ожидать калиброванную модель на выходе.